

7506-2021 Examen por Promoción 1C-2021

Román Vázquez Lareu

TOTAL POINTS

47.5 / 100

QUESTION 1

1 Pto 1 15 / 20

- ✓ - 5 pts Idea correcta pero no aplica el algoritmo. Solo muestra el resultado final que aparece "magicamente".

Este split no fue entrenado en train, el split que le conviene al arbol es C2 y tendría accuracy 1

- 4 Este no es el MSE
- 5 Te faltan datasets y decir cuál es la regresión

QUESTION 2

2 Pto 2 12 / 15

- ✓ - 3 pts Para calcular la correlacion, toma el promedio de todos los elementos y no de los que tiene en comun con el otro vector.
- 1 Es mejor ajustar con el promedio de los elementos que tiene en comun con el vector a comparar, y no con todos.

QUESTION 3

3 Pto 3 12 / 20

- ✓ - 6 pts Solo plantea parte b.
- ✓ - 2 pts Faltan iteraciones parte a.

QUESTION 4

4 Pto 4 5 / 15

- ✓ - 5 pts Punto c para que realmente no funcione deberia generar todos ceros, lo que plantea podria funcionar luego con mas elementos.
- ✓ - 5 pts Mal punto b.
- 2 Esto no esta nada bien.

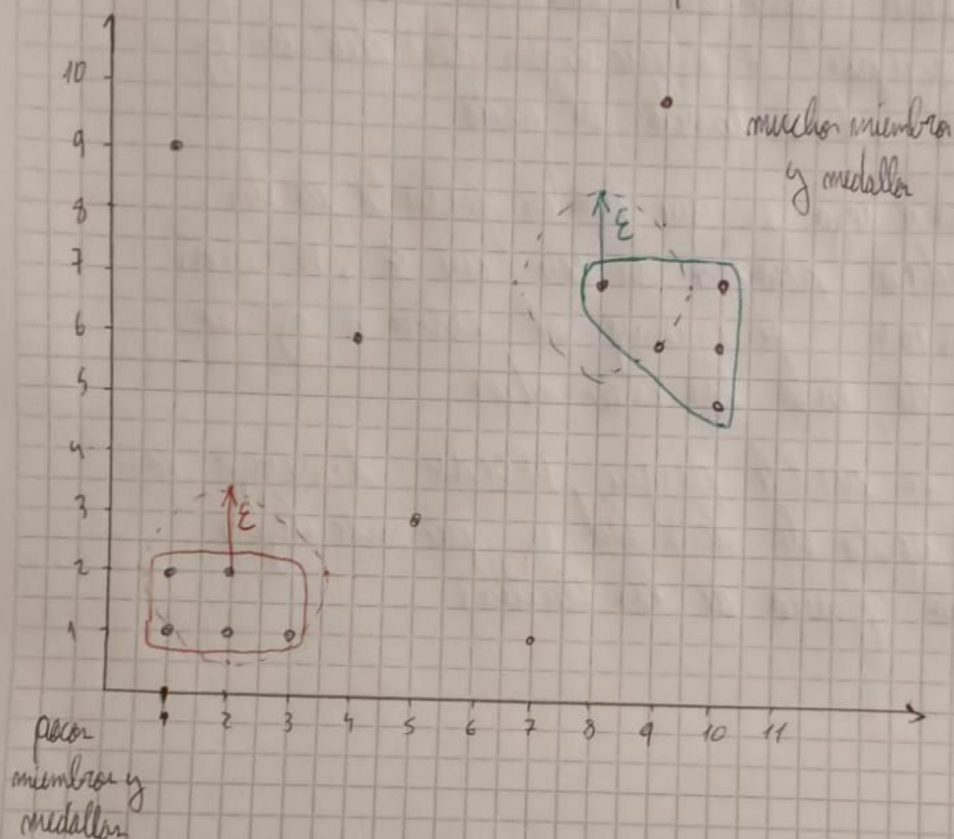
QUESTION 5

5 Pto 5 3.5 / 30

- ✓ - 7.5 pts a) No resuelto
- ✓ - 7.5 pts b) No resuelto
- ✓ - 7.5 pts d) No resuelto
- ✓ - 4 pts c) El arbol no es correcto

3

1) Lo que interesa es hallar a los poderosos y a los débiles, por lo que los que se encuentran entre medio podrían ser considerados como ruido \Rightarrow planteo DBSCAN para eliminarlos



Con la solución actual los 2 grupos que quedan formados no aportan información ya que tienen presentes puntos que no pertenecen de acuerdo a lo que queremos.

DBSCAN permite tener puntos que no son de ningún cluster, que es lo que queremos

Con un $E = 1.5$ y un $K = 2$ se obtiene la configuración del gráfico. Si bien no logra incluir al punto extremo $(9, 10)$, lo que nos brinda esta situación a diferencia de la anterior son ciertos.

Con total seguridad podemos afirmar que en esos grupos se encuentran los débiles y poderosos, descartando al resto.

Como desventaja es que pueden faltarle puntos. Se podría probar si con un E , K más permisivos se incluye al extremo y se dejan de lado los intermedios.

Esto es posible porque DBSCAN trabaja con el concepto de densidad y permite dejar puntos fuera de los clusters.

1 Pto 1 15 / 20

✓ - 5 pts Idea correcta pero no aplica el algoritmo. Solo muestra el resultado final que aparece "magicamente".

2) CF user-user

Pearson para 2 usuarios más similares.

Estimar calificación del user "a" a item 3

	1	2	3	4	5	6	7	8
a	1			5	1		2	3
b	3	2		1	1		3	2
c	2		(4)		2		4	2
d	1	2			1			3
e		3	(3)		1	4		2
f	4		(5)	1		4	1	

$$\text{sim}(x, y) = \frac{\sum_{i \in S_{xy}} (r_{xi} - \bar{r}_x) (r_{yi} - \bar{r}_y)}{\sqrt{\sum_{i \in S_{xy}} (r_{xi} - \bar{r}_x)^2} \sqrt{\sum_{i \in S_{xy}} (r_{yi} - \bar{r}_y)^2}}$$

$\text{sim}(x, y)$ → vector de usuario "a"
 \bar{r}_x → promedio de elementos en común
 \bar{r}_y → promedio de elementos en común
 S_{xy} → elementos en común
 r_{xi} → calificación de usuario x en item i
 r_{yi} → calificación de usuario y en item i

$$c = [2 \quad - \quad 4 \quad - \quad 2 \quad - \quad 4 \quad 2] \rightarrow \text{promedio} = 2,3$$

$$e = [- \quad 3 \quad 3 \quad - \quad 1 \quad 4 \quad - \quad 2] \rightarrow \text{promedio} = 2,6$$

$$f = [4 \quad - \quad 5 \quad 1 \quad - \quad - \quad 4 \quad 1] \rightarrow \text{promedio} = 3$$

$$a = [1 \quad - \quad - \quad 5 \quad 1 \quad - \quad 2 \quad 3] \rightarrow \text{promedio} = 2,4$$

rento los promedios por anuncio

$$c = [-0,8 \quad -1,2 \quad -0,8 \quad -1,2 \quad -0,8]$$

$$e = [-0,4 \quad 0,4 \quad -1,6 \quad 1,4 \quad -0,6]$$

$$b = [1 \quad -2 \quad -2 \quad -1 \quad -2]$$

$$a = [-1,4 \quad -2,6 \quad -1,4 \quad -0,4 \quad 0,6]$$

a) entre a y c : $c = [-0,8 \quad -0,8 \quad -1,2 \quad -0,8] \rightarrow [-0,4764 \quad -0,4764 \quad 0,6546 \quad -0,4764]$

$$a = [-1,4 \quad -1,4 \quad -0,4 \quad 0,6] \rightarrow [-0,0265 \quad -0,0265 \quad -0,007 \quad 0,0413]$$

$$\text{sim}(a, c) = [-0,4764 \quad -0,4764 \quad 0,6546 \quad -0,4764] + [-0,0265 \quad -0,0265 \quad -0,007 \quad 0,0413] = 0,10136$$

b) a y e : $e = [-1,6 \quad -0,6] \rightarrow [0,9363 \quad 0,3511]$

$$a = [-1,4 \quad 0,6] \rightarrow [0,9191 \quad 0,3939]$$

$$\text{sim}(a, e) = [0,9363 \quad 0,3511] + [0,9191 \quad 0,3939] = 0,9989$$

c) a y b : $b = [1 \quad -2 \quad -2 \quad -1 \quad -2] \rightarrow [0,7162 \quad -0,1324 \quad 0,3162 \quad -0,6624]$

$$a = [-1,4 \quad 2,6 \quad -0,4 \quad 0,6] \rightarrow [-0,7606 \quad 0,9553 \quad -0,1746 \quad 0,1979]$$

$$\text{sim}(a, b) = -0,8529$$

c negativa \Rightarrow la desactiva
puede hacer divergir
la optimización

más similares son e y c. Ahora estimo
la calificación

$$r_{xi} = \frac{\sum_{j \in N} s_{xy} r_{yj}}$$

$$\sum_{j \in N} s_{xy}$$

nota de c a item

nota de e a item 3

$$r_{a, \text{item 3}} = \frac{0,0136 \cdot 4 + 0,9989 \cdot 3}{0,0136 + 0,9989} = 3,0139$$

pondero la calificación por la similitud y divido
por la suma de similitudes.

\Rightarrow como las calificaciones deben ser
enteras

$$r_{a, \text{item 3}} = 3$$

2 Pto 2 12 / 15

✓ - 3 pts Para calcular la correlacion, toma el promedio de todos los elementos y no de los que tiene en comun con el otro vector.

1 Es mejor ajustar con el promedio de los elementos que tiene en comun con el vector a comparar, y no con todos.

$$3) \quad m = 8 \quad 1 - \beta = 0,2 \quad (1 - \beta) \frac{1}{m} = \frac{1}{40}$$

$$\beta = 0,8$$

con proba β reparte a todos que línea equitativamente
con proba $1 - \beta$ asigna $1/m$ a todos

INICIALIZACIÓN 1^{era} iter

$$P_{0,1} = 1/8 \quad P_{0,2} = 0,8 [0] + 1/40 = 1/40$$

$$P_{1,1} = 1/8 \quad P_{1,2} = 0,8 [\frac{1}{2} P_{0,1} + P_{2,1}] + 1/40 = 7/40$$

$$P_{2,1} = 1/8 \quad P_{2,2} = 0,8 [\frac{1}{2} P_{0,1} + \frac{1}{4} P_{3,1}] + 1/40 = 4/40$$

$$P_{3,1} = 1/8 \quad P_{3,2} = 0,8 [P_{8,1}] + 1/40 = 1/8$$

$$P_{4,1} = 1/8 \quad P_{4,2} = 0,8 [P_{1,1} + \frac{1}{4} P_{3,1}] + 1/40 = 3/20$$

$$P_{5,1} = 1/8 \quad P_{5,2} = 0,8 [\frac{1}{2} P_{4,1} + \frac{1}{4} P_{3,1}] + 1/40 = 1/10$$

$$P_{6,1} = 1/8 \quad P_{6,2} = 0,8 [\frac{1}{4} P_{3,1}] + 1/40 = 2/40$$

$$P_{8,1} = 1/8 \quad P_{8,2} = 0,8 [P_{6,1} + \frac{1}{2} P_{4,1} + P_{5,1}] + 1/40 = 11/40$$

suman 1, bien los cuantos

2^{da} iter

$$P_{0,3} = 0,8 [0] + 1/40 = 1/40$$

$$P_{1,3} = 0,8 [\frac{1}{2} P_{0,2} + P_{2,2}] + 1/40 = 23/200$$

$$P_{2,3} = 0,8 [\frac{1}{2} P_{0,2} + \frac{1}{4} P_{3,2}] + 1/40 = 3/50$$

$$P_{3,3} = 0,8 [P_{8,2}] + 1/40 = 49/200$$

$$P_{4,3} = 0,8 [P_{1,2} + \frac{1}{4} P_{3,2}] + 1/40 = 19/100$$

$$P_{5,3} = 0,8 [\frac{1}{2} P_{4,2} + \frac{1}{4} P_{3,2}] + 1/40 = 11/100$$

$$P_{6,3} = 0,8 [\frac{1}{4} P_{3,2}] + 1/40 = 1/20$$

$$P_{8,3} = 0,8 [P_{6,2} + \frac{1}{2} P_{4,2} + P_{5,2}] + 1/40 = 41/200$$

iteraciones hasta

... Convergen

Por ej:

$$P_{5,m} = 0,8 [\frac{1}{2} P_{4,m-1} + \frac{1}{4} P_{3,m-1}] + 1/40$$

suman 1, bien los cuantos

debe seguir iterando de esta manera hasta
converger, es decir que los valores no se modifiquen.
En cada nueva iteración, utilizaremos para el cálculo la
obtenido en la anterior

Si la P_{avg} o no es confiable, entonces no
la voy a querer favorecer con la teletransportación.

Así, en primer lugar no le voy a sumar el $(1-\beta) \frac{1}{m}$.

En segundo lugar, lo que no le doy a PO se
distribuirá entre el resto, por lo que
la suma por teletransportación para el resto
será de $(1-\beta) \cdot \frac{1}{m}$ con $m=7$ ya que
no tengo en cuenta PO.

A modo de ejemplo:

$$P_{0m} = 0,8 \cdot L_0$$

$$P_{1m} = 0,8 \left[\frac{1}{2} P_{0m-1} + P_{2m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{2m} = 0,8 \left[\frac{1}{2} P_{0m-1} + \frac{1}{4} P_{3m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{3m} = 0,8 \left[P_{3m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{4m} = 0,8 \left[P_{1m-1} + \frac{1}{4} P_{3m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{5m} = 0,8 \left[\frac{1}{2} P_{4m-1} + \frac{1}{4} P_{3m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{6m} = 0,8 \left[\frac{1}{4} P_{3m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

$$P_{8m} = 0,8 \left[P_{6m-1} + \frac{1}{2} P_{4m-1} + P_{5m-1} \right] + (1-0,8) \cdot \frac{1}{7}$$

Los valores de iteración se conservan

3 Pto 3 12 / 20

✓ - 6 pts Solo plantea parte b.

✓ - 2 pts Faltan iteraciones parte a.

5) a)

$$S = [3, 6, 6, 3, 3, 6, 5, 6]$$

$$h(x) = x \bmod 32$$

$M^0(5)$ usando Flajolet Martin con 1 estimador
5 bits considerando los ceros a derecha.

$$M^0(5) = 3 \text{ porque observe } 3, 6 \text{ y } 5$$

x	H(x)
3	$3_{10} = 00011_2$
5	$5_{10} = 00101_2$
6	$6_{10} = 00110_2$

FM aproxima con 2^r , por lo que r debería ser 1 o 2

$H(3) = 00011$	$r = 0$
$H(6) = 00110$	$r = 1$
$H(6) = 00110$	$r = 1$
$H(3) = 00011$	$r = 1$
$H(3) = 00011$	$r = 1$
$H(6) = 00110$	$r = 1$
$H(5) = 00101$	$r = 1$
$H(6) = 00110$	$r = 1$

$$M^0(5) = 2^1 = 2$$

para aproximar bien r debía ser 1 o 2 y dio bien.
Hay que tener en cuenta que al recibir un número impar, nunca
podrá detectarlo como nuevo elemento ya que termina en 1

conclusion

$$y = mx + b = x$$

Esto no es bueno. Si bien dio bien la aproximación en este caso, la función no es buena ya que no cuenta como ~~buena~~ impar.
 B. si plantea $3x + 1 \mod 32 = h(x)$

x	H(x)
3	$10_2 = 1010_2$
5	$16_2 = 10000_2$
6	$19_2 = 10011_2$

si bien en este caso no aproximaría bien, de nuevo otra función sería mejor. Si quisiera que aproximara para este caso únicamente, con $x+1 \mod 32$ lograría tener un $t=2$ aproximando a 4.

Esta función parece que funcionaría mejor ya que daría mejor respuesta a los impares. A su vez, si "a" fuera par, devaluaría todo par e impar, esta función lo evita. En términos binarios distribuye mejor los 0, 00, 000, etc.

C. si plantea $h(x) = 2x + 1 \mod 32$

x	H(x)
3	7
5	11
6	13

da siempre impar, el bit de la derecha será siempre 1, por lo que t no cambiaría su valor

4 Pto 4 5 / 15

✓ - 5 pts Punto c para que realmente no funcione debería generar todos ceros, lo que plantea podría funcionar luego con mas elementos.

✓ - 5 pts Mal punto b.

2 Esto no esta nada bien.

3c) X - train set


$$3 \text{ bits} \Rightarrow \log_2 3 + 2 \text{ bits}$$

	binary encoding	
A	0	0
B	0	1
C	1	0
D	1	1
	c_1	c_2

X:	label	c_1	c_2	
A	0	0	0	0
B	1	0	1	1
C	0	1	0	0
C	0	1	0	0
		real	prediction	
0	0	0	0	
1	1	0	1	3
0	1	1	1	

$$\mathcal{E}(h) = \frac{1}{4} \|\{h(x_i) \neq y_i\}\| = \frac{1}{4} \cdot 4 = 1.0$$

$$\Rightarrow \text{accuracy} = 0.75$$



- valores de test

- valores de train

los valores d_1 y d_2 tienen que ser
tales que $d_1^2 + d_2^2 = 0.5$

$$\text{el error cuadrático es } J(\theta) = \sum (h_0(x) - y)^2$$

5 Pto 5 3.5 / 30

✓ - 7.5 pts a) No resuelto

✓ - 7.5 pts b) No resuelto

✓ - 7.5 pts d) No resuelto

✓ - 4 pts c) El arbol no es correcto

3 Este split no fue entrenado en train, el split que le conviene al arbol es C2 y tendría accuracy 1

4 Este no es el MSE

5 Te faltan datasets y decir cuál es la regresión